

UNIVERSIDADE PRESBITERIANA MACKENZIE

**Eduardo Pinheiro Canas
Hugo de Moraes Holzer
Luiz Rodrigo Alves Vergino**

SISTEMA DE RECOMENDAÇÃO DE CURSOS ONLINE
Uma abordagem por KNN baseada em conteúdo usando Python

São Paulo
2026

**Eduardo Pinheiro Canas
Hugo de Moraes Holzer
Luiz Rodrigo Alves Vergino**

SISTEMA DE RECOMENDAÇÃO DE CURSOS ONLINE
Uma abordagem por KNN baseada em conteúdo usando Python

Projeto aplicado III apresentado ao Programa de Graduação da Universidade Presbiteriana Mackenzie como requisito parcial para obtenção do título Tecnólogo em Ciência de Dados.

Orientadora: Professora Doutora Carolina Toledo Ferraz

São Paulo
2026

Sumário


Table of Contents

1. INTRODUÇÃO.....	4
1.1. CONTEXTO DO TRABALHO.....	4
1.2. MOTIVAÇÃO.....	5
1.3. JUSTIFICATIVAS	5
1.4. OBJETIVOS.....	5
1.5. OBJETIVOS ESPECÍFICOS	6
1.6. OBJETIVO EXTENSIONISTA.....	6
1.7. DEFINIÇÃO DA BASE	7
1.8. REFERENCIAL TEÓRICO	8
1.8.1. Bibliotecas Python Utilizadas.....	8
1.8.2. Filtragem Baseada em Conteúdo	9
1.8.3. Pré-processamento e Engenharia de Features.....	9
1.8.4. Vetorização TF-IDF.....	10
1.8.5. Algoritmo K-Nearest Neighbors (KNN).....	10
1.8.6. Métricas de Avaliação	11
2. CRONOGRAMA DE ATIVIDADES.....	12
3. ANÁLISE EXPLORATÓRIA DE DADOS	13
3.1. Visão Geral do Conjunto de Dados.....	13
3.2. Qualidade e Consistência dos Dados.....	13
3.3. Distribuição das Notas dos Cursos	14
3.4. Distribuição por Nível de Dificuldade	14
3.5. Universidades com Maior Oferta de Cursos	14
3.6. Nota Média por Nível de Dificuldade	15
3.7. Habilidades Mais Frequentes no Catálogo	15
3.8. Padrões e Características Relevantes Identificados.....	16

1. INTRODUÇÃO

Faremos a organização e mapeamento de tudo o que for realizado durante as entregas através do Github criado especificamente para este trabalho. O link do repositório está fixado abaixo e poderá ser acessado por todos os integrantes e também pelo corpo docente para atualizações e acompanhamento.

<https://github.com/canasep/mackprojeto3>



1.1. CONTEXTO DO TRABALHO

Os sistemas de recomendação estão cada vez mais presentes no cotidiano digital, ajudando usuários a encontrar conteúdos, produtos e serviços de forma personalizada. Plataformas de ensino online como Coursera, edX e Udemy utilizam técnicas de Machine Learning para sugerir cursos alinhados ao perfil e aos interesses de cada aprendiz.

Dentro desse contexto, este Projeto Aplicado propõe o desenvolvimento de um sistema de recomendação de cursos online a partir de uma base de dados real da plataforma Coursera, passando pelas etapas de planejamento, análise, modelagem e avaliação do desempenho. A abordagem adotada é a filtragem baseada em conteúdo (content-based filtering), utilizando o algoritmo K-Nearest Neighbors (KNN) aplicado

sobre vetores TF-IDF extraídos das habilidades (skills), descrições e níveis de dificuldade dos cursos.

O projeto está alinhado ao Objetivo de Desenvolvimento Sustentável nº 4 da ONU (ODS 4 – Educação de Qualidade) e ao ODS 8 (Trabalho Decente e Crescimento Econômico), buscando contribuir com a democratização do acesso ao conhecimento e ao desenvolvimento profissional por meio da tecnologia.

1.2. MOTIVAÇÃO

A motivação em desenvolver este trabalho surge da importância crescente das plataformas de ensino online no cenário educacional atual, especialmente após a aceleração da transformação digital. Entender como os sistemas de recomendação funcionam na prática é uma forma de aplicar os conceitos de Machine Learning estudados ao longo do curso em uma situação real e de alto impacto social. Existe também um interesse genuíno do grupo em compreender como diferentes abordagens de recomendação se diferenciam em termos de aplicabilidade e resultados.

1.3. JUSTIFICATIVAS

Nosso objetivo com este Projeto Aplicado é descobrir quais abordagens são mais adequadas para bases de dados sem histórico explícito de interações de usuários, como o processo de extração e vetorização de características textuais impacta a qualidade das recomendações, e quais métricas conseguem avaliar de forma eficiente um sistema baseado em conteúdo. Também buscaremos entender melhor os desafios envolvidos na construção de todo o pipeline, desde a preparação dos dados até a análise crítica dos resultados obtidos.

1.4. OBJETIVOS

Desenvolver um sistema em forma de notebook-python (ipynb) de recomendação de cursos online baseado em técnicas de Machine Learning, utilizando uma base de dados real da plataforma Coursera para gerar sugestões personalizadas a partir das características dos cursos. Implementar e avaliar a abordagem de filtragem baseada em conteúdo com KNN e TF-IDF, aplicando métodos de

preparação, treinamento e validação dos dados. Analisar o desempenho do sistema por meio de métricas apropriadas. Documentar todas as etapas do processo em formato científico. Contribuir com uma solução alinhada aos Objetivos de Desenvolvimento Sustentável (ODS 4 e ODS 8).

Ao final, esperamos desenvolver não apenas habilidades técnicas como análise de dados, modelagem e avaliação de algoritmos, mas também compreender como sistemas de recomendação de conteúdo educacional podem contribuir para ampliar o acesso ao conhecimento e ao desenvolvimento profissional de forma democrática.

1.5. OBJETIVOS ESPECÍFICOS

- Definir o tema do sistema de recomendação e selecionar uma base de dados adequada ao problema proposto.
- Realizar a análise exploratória dos dados (EDA) para compreender suas características, padrões e limitações.
- Executar a limpeza, o tratamento e a preparação dos dados para o treinamento do modelo.
- Aplicar técnicas de vetorização textual (TF-IDF) sobre as colunas de habilidades e descrição dos cursos.
- Implementar o algoritmo KNN com similaridade de cosseno para recomendação baseada em conteúdo.
- Definir métricas de avaliação adequadas para medir o desempenho do sistema.
- Treinar e validar o modelo de recomendação, analisando seus resultados.
- Comparar possíveis abordagens, quando aplicável, para identificar a mais eficiente.
- Documentar a metodologia, os experimentos realizados e os resultados obtidos.
- Analisar criticamente os pontos fortes e limitações do sistema desenvolvido.
- Propor melhorias e possíveis trabalhos futuros relacionados ao projeto.

1.6. OBJETIVO EXTENSIONISTA

Este projeto possui um caráter extensionista alinhado a dois Objetivos de Desenvolvimento Sustentável da ONU: o ODS 4 (Educação de Qualidade), que busca assegurar a educação inclusiva, equitativa e de qualidade, promovendo oportunidades de aprendizado ao longo da vida para todos; e o ODS 8 (Trabalho Decente e

Crescimento Econômico), que visa promover o crescimento econômico sustentado, inclusivo e sustentável, o emprego pleno e produtivo e o trabalho decente para todos.

A construção de um sistema de recomendação de cursos online tem potencial impacto social direto: ao sugerir trilhas de aprendizado personalizadas com base nas habilidades e no nível de experiência do usuário, a solução desenvolvida pode auxiliar pessoas a encontrarem cursos alinhados ao seu desenvolvimento profissional e acadêmico, independentemente de seu acesso a orientação educacional especializada. Em um cenário de transformação digital acelerada, onde a qualificação contínua tornou-se essencial para a empregabilidade, ferramentas que ampliam o acesso ao ensino de qualidade possuem relevância social concreta.

Dessa forma, o projeto contribui não apenas com o avanço técnico-científico na área de Ciência de Dados, mas também com a proposição de uma solução tecnológica voltada ao bem comum, em consonância com os princípios extensionistas da Universidade Presbiteriana Mackenzie.

1.7. DEFINIÇÃO DA BASE

Para este projeto, optamos pela utilização do Coursera Courses Dataset 2021, disponível publicamente na plataforma Kaggle. A base contém informações de 3.522 cursos da plataforma Coursera, organizadas em 7 colunas: nome do curso, universidade, nível de dificuldade, nota média, URL do curso, descrição e habilidades desenvolvidas (skills). Por não possuir avaliações individuais de usuários, a abordagem adotada é a filtragem baseada em conteúdo, utilizando vetorização TF-IDF sobre as colunas de habilidades e descrição para construir a representação de cada curso, seguida da aplicação do algoritmo KNN com similaridade de cosseno para identificar os cursos mais similares.

Coursera Courses Dataset 2021

111

<> Code

Download



Data Card Code (18) Discussion (1) Suggestions (0)

Coursera.csv (5.28 MB)



Detail Compact Column

7 of 7 columns

About this file

Suggest Edits

This table contains information publicly available on the Coursera website. The columns are: Name, University, Difficulty Level, Rating, Link, Description and Skills.

Course Name	University	Difficulty Level	Course Rating	Course URL	Course Description	Skills
The Name of the Course.	The University or Industry Partner that offers the Course.	The Difficulty Level of the Course. Has 3 values: Beginner, Intermediate, Advanced. Also has Missing Values	Rating on a 5-point scale with minimum step value 0.1. Missing Values represented by Not Calibrated.	The Course URL.	The Description of the Course. Has Missing Values.	The Skill Tags associated with the Course extracted through NLP processes.
3416 unique values	Coursera Project ... 16% University of Illinoi... 4% Other (2822) 80%	Beginner 41% Advanced 29% Other (1073) 30%	4.7 21% 4.6 18% Other (2159) 61%	3424 unique values	3397 unique values	3424 unique values

<https://www.kaggle.com/datasets/khusheekapoor/coursera-courses-dataset-2021>

1.8. REFERENCIAL TEÓRICO

1.8.1. Bibliotecas Python Utilizadas

O desenvolvimento do sistema foi realizado em Python, com as seguintes bibliotecas:

Pandas é a principal biblioteca para manipulação e análise de dados tabulares em Python. Neste projeto, é utilizada para carregar o dataset em formato CSV, padronizar e renomear colunas, tratar valores nulos, realizar agrupamentos e filtros, e construir os DataFrames de resultado das recomendações.

NumPy fornece suporte a operações matemáticas e vetoriais de alto desempenho. É utilizado para geração de amostras aleatórias na etapa de avaliação, cálculo de médias dos scores e manipulação de arrays de distâncias retornados pelo modelo KNN.

Matplotlib é a biblioteca base de visualização de dados. É utilizada para geração de histogramas de distribuição de notas, gráficos de barras por nível de dificuldade, gráficos de barras horizontais com as top universidades e skills, e comparativos entre recomendações e base geral.

Seaborn estende o Matplotlib com visualizações estatísticas de alto nível. É utilizada especificamente para o heatmap de similaridade de cosseno entre os 12 cursos mais bem avaliados, com anotação dos valores em cada célula da matriz.

Re (Regular Expressions) é o módulo nativo do Python para processamento de expressões regulares. É utilizado na função `limpar_texto()` para remover caracteres especiais, pontuação e normalizar espaços em branco nas colunas textuais antes da vetorização.

Scikit-learn é a principal biblioteca de Machine Learning utilizada no projeto. Três componentes são empregados: o **TfidfVectorizer** para transformar texto em vetores numéricos ponderados; o **NearestNeighbors** para treinar o modelo KNN de busca por vizinhos mais próximos; e o **cosine_similarity** para calcular a matriz de similaridade entre os cursos na etapa de avaliação e visualização.

1.8.2. Filtragem Baseada em Conteúdo

A filtragem baseada em conteúdo é uma abordagem de sistemas de recomendação que sugere itens com base nas características dos próprios itens, sem depender de dados de comportamento de outros usuários. Cada item é representado por um conjunto de atributos, como descrição, categorias e palavras-chave. A similaridade entre itens é calculada a partir dessas representações. Por não exigir histórico de interações de múltiplos usuários, é especialmente adequada para o Coursera Courses Dataset 2021, que contém informações detalhadas sobre os cursos mas não registra avaliações individuais de usuários.

1.8.3. Pré-processamento e Engenharia de Features

Antes da vetorização, os dados passam por duas etapas. Na limpeza textual, a função `limpar_texto()` converte o texto para letras minúsculas, remove caracteres especiais e pontuação via expressões regulares, e normaliza espaços múltiplos. Valores nulos nas colunas `skills`, `description` e `difficulty` são substituídos por strings vazias ou pelo valor mediano, garantindo que nenhum registro seja descartado.

Na engenharia de features, as colunas skills, difficulty e description são combinadas em um único campo textual denominado features. A coluna skills é concatenada duas vezes para aumentar seu peso relativo na vetorização TF-IDF, estratégia que favorece a recomendação por similaridade de habilidades — o critério mais relevante para o usuário final que busca cursos alinhados ao seu perfil profissional.

1.8.4. Vetorização TF-IDF

TF-IDF (Term Frequency-Inverse Document Frequency) é uma técnica estatística de ponderação que reflete a importância de uma palavra em um documento em relação a uma coleção (corpus) de documentos. É amplamente utilizada em recuperação de informação e mineração de texto.

O TF-IDF é composto por dois termos. A Frequência do Termo (TF) mede quantas vezes uma palavra aparece em um documento, normalizada pelo total de termos: $TF(t,d) = \text{ocorrências de } t \text{ em } d / \text{total de termos em } d$. A Frequência Inversa do Documento (IDF) mede o quão rara é uma palavra na coleção inteira — termos comuns recebem peso menor, termos raros recebem peso maior: $IDF(t,D) = \log(\text{total de documentos} / \text{documentos que contêm } t)$. O valor final é calculado como: $TF-IDF(t,d,D) = TF(t,d) \times IDF(t,D)$.

Neste projeto, o TfidfVectorizer é configurado com max_features=5000 (limita o vocabulário aos 5.000 termos mais relevantes), ngram_range=(1,2) (considera unigramas e bigramas como "machine learning" e "data science"), min_df=2 (ignora termos que aparecem em menos de 2 cursos) e stop_words="english" (remove palavras comuns do inglês sem valor semântico). O resultado é uma matriz esparsa de dimensão 3.522 cursos × 5.000 termos.

1.8.5. Algoritmo K-Nearest Neighbors (KNN)

O K-Nearest Neighbors (KNN) é um algoritmo de aprendizado de máquina baseado em instâncias que, no contexto de recomendação, identifica os K itens mais similares a um item de consulta. Para cada curso, o modelo calcula a distância em

relação a todos os demais no espaço vetorial gerado pelo TF-IDF, retornando os K cursos com maior proximidade como recomendações.

O modelo é configurado com `metric="cosine"` (similaridade de cosseno, ideal para vetores TF-IDF esparsos), `algorithm="brute"` (busca exata, adequada para o tamanho do dataset) e `n_neighbors=10`. A similaridade de cosseno mede o ângulo entre dois vetores independentemente de sua magnitude: valor próximo a 1 indica cursos muito similares em conteúdo; próximo a 0, cursos sem relação entre si.

A função de recomendação opera em dois modos: por nome de curso existente na base, localizando o vetor do curso e retornando os K vizinhos mais próximos (excluindo o próprio curso); ou por skill/tema livre, vetorizando a query com o mesmo `TfidfVectorizer` treinado e retornando os K cursos mais próximos do vetor de consulta.

1.8.6. Métricas de Avaliação

Por não haver avaliações individuais de usuários, as métricas adotadas são adequadas à abordagem content-based. A Cobertura do catálogo mede o percentual de cursos que são recomendados ao menos uma vez numa amostra de 200 consultas, indica se o modelo explora bem o catálogo ou concentra recomendações em poucos itens. A Similaridade média mede, em percentual, o quão próximos são os cursos recomendados do curso de consulta e avalia a precisão das recomendações. A Diversidade média mede o quão distintos são os K cursos recomendados entre si, um modelo que recomenda sempre cursos muito parecidos tem baixa diversidade, prejudicando a experiência do usuário. A Qualidade das recomendações compara a nota média dos cursos recomendados com a nota média global do dataset, ou seja, recomendações com nota acima da média global indicam que o modelo tende a sugerir cursos bem avaliados pela comunidade.

2. CRONOGRAMA DE ATIVIDADES

Tabela 1: Cronograma com etapas do trabalho e entregas definidas

Prazo	Atividade	Descrição	Responsável
01/03/2026	Criação do Repositório	Criação do Github que servirá como repositório de arquivos e entregas realizadas.	Eduardo Pinheiro Canas
01/03/2026	Definição do sistema de recomendação e demais atividades da primeira entrega	Primeira reunião do grupo para estruturar o trabalho e realizar a primeira entrega.	Todos os integrantes
03/03/2025	Envio da Etapa 1	Entrega da Primeira Etapa para avaliação do Professor Orientador.	Todos os integrantes
14/03/2026	Revisão da Etapa 1	Revisão do trabalho e ajustes conforme feedback do professor.	Todos os integrantes
21/03/2026	Reunião do Grupo para Início da Etapa 2	Discussão de pontos chave e início da confecção da segunda entrega.	Todos os integrantes
28/03/2026	Reunião do Grupo para Finalização da Etapa 2	Estruturação do trabalho e ajustes finos para a realização da segunda entrega.	Todos os integrantes
30/03/2026	Envio da Etapa 2	Entrega da Segunda Etapa para avaliação do professor.	Todos os integrantes
04/04/2026	Revisão da Etapa 2	Revisão do trabalho e ajustes conforme feedback do professor.	Todos os integrantes
11/04/2026	Reunião do Grupo para Início Etapa 3	Discussão de pontos chave e início da confecção da terceira entrega.	Todos os integrantes
18/04/2026	Reunião do Grupo para Finalização da Etapa 3	Estruturação do trabalho e ajustes finos para a realização da terceira entrega.	Todos os integrantes
27/04/2026	Envio da Etapa 3	Entrega da Terceira Etapa para avaliação do professor.	Todos os integrantes
02/05/2026	Revisão da Etapa 3	Revisão do trabalho e ajustes conforme feedback do professor.	Todos os integrantes
09/05/2026	Reunião do Grupo para Início Etapa 4	Discussão de pontos chave e início da confecção da quarta entrega.	Todos os integrantes
16/05/2026	Reunião do Grupo para Finalização da Etapa 4	Estruturação do trabalho e ajustes finos para a realização da quarta entrega.	Todos os integrantes
18/05/2026	Envio Final da Etapa 4	Entrega final da Quarta Etapa.	Todos os integrantes

Fonte: Elaborado pelos autores

3. ANÁLISE EXPLORATÓRIA DE DADOS

3.1. Visão Geral do Conjunto de Dados

O dataset utilizado neste trabalho é o Coursera Courses Dataset 2021, disponibilizado publicamente na plataforma Kaggle. Após o carregamento via API Kaggle (`kaggle datasets download`), o DataFrame apresentou dimensões de 3.522 linhas por 7 colunas, representando cursos individuais com os seguintes atributos: nome do curso (`name`), instituição ofertante (`university`), nível de dificuldade (`difficulty`), avaliação média dos usuários (`rating`), URL de acesso (`url`), descrição textual (`description`) e habilidades desenvolvidas (`skills`).

A padronização dos nomes das colunas foi realizada previamente à análise exploratória, convertendo os cabeçalhos para letras minúsculas e removendo espaços excedentes, garantindo consistência no acesso programático aos campos. As estatísticas descritivas completas foram obtidas por meio do método `describe()` da biblioteca Pandas, aplicado a todas as variáveis do DataFrame.

3.2. Qualidade e Consistência dos Dados

Antes da análise exploratória, foi realizada uma inspeção de qualidade da base de dados por meio da verificação de valores nulos em todas as colunas (`df.isnull().sum()`). As colunas textuais `description` e `skills` concentram a maior parte dos registros ausentes, enquanto os campos `name`, `university` e `difficulty` apresentam completude satisfatória, não comprometendo a representatividade do conjunto.

Um ponto de atenção identificado refere-se à coluna `rating`: o campo foi convertido explicitamente para o tipo numérico utilizando `pd.to_numeric(..., errors='coerce')`, o que indica a presença de valores não numéricos no dado bruto — possivelmente registros com texto como "Not Calibrated" ou campos em branco. Essa abordagem converte tais ocorrências em NaN, que foram subsequentemente ignoradas nas análises de distribuição e agrupamento. Nenhum tratamento de duplicatas foi necessário, pois os registros de cursos são identificados por URLs únicas na plataforma.

3.3. Distribuição das Notas dos Cursos

O histograma de distribuição das notas revela que a grande maioria dos cursos concentra suas avaliações entre 4,0 e 4,9 pontos, em uma escala de 0 a 5. A linha de média evidencia uma tendência de avaliação elevada, indicando que a plataforma Coursera hospeda predominantemente cursos bem avaliados pelos usuários.

Essa distribuição assimétrica à esquerda (left-skewed) sugere baixa presença de cursos com notas abaixo de 3,5, o que pode influenciar a capacidade do sistema de recomendar cursos altamente avaliados com naturalidade, sem necessidade de filtro explícito por qualidade.

3.4. Distribuição por Nível de Dificuldade

O gráfico de barras por nível de dificuldade demonstra que o nível Beginner concentra o maior volume de cursos na plataforma (1.622), seguido por Intermediate (1.048), Mixed (567) e Advanced (285). Os rótulos de valor foram adicionados ao topo de cada barra para facilitar a leitura quantitativa.

Essa distribuição é relevante para o sistema de recomendação, pois indica que usuários iniciantes dispõem de um catálogo significativamente maior para exploração, enquanto usuários avançados encontrarão um leque mais restrito, porém potencialmente mais especializado. O padrão reflete também o modelo de negócio da plataforma, voltado em grande parte à capacitação e ao desenvolvimento de novas competências.

3.5. Universidades com Maior Oferta de Cursos

O gráfico horizontal das 10 universidades com maior número de cursos evidencia uma concentração da oferta em poucas grandes instituições e empresas de tecnologia. Organizações como DeepLearning.AI, IBM e Google Cloud figuram entre os principais ofertantes, ao lado de renomadas universidades norte-americanas como University of Michigan, Duke University e University of Pennsylvania.

Esse padrão reflete a forte presença de conteúdo nas áreas de ciência de dados, computação em nuvem e inteligência artificial. Para o sistema de recomendação, isso implica que resultados tendem a concentrar cursos dessas instituições.




Figura 1 – Distribuição de notas, cursos por dificuldade e top 10 universidades

3.6. Nota Média por Nível de Dificuldade

A análise da nota média agrupada por nível de dificuldade revela que cursos de nível Mixed (4,72) e Beginner (4,69) tendem a apresentar avaliações ligeiramente superiores em relação aos níveis Intermediate (4,65) e Advanced (4,61). Os valores médios exibidos sobre as barras do gráfico indicam uma diferença pequena, porém consistente entre os grupos.

Esse padrão sugere que cursos mais acessíveis tendem a receber avaliações mais positivas, na nossa opinião isso acontece pela menor frustração dos usuários durante o aprendizado ou pelo maior número de avaliações acumuladas nesses níveis, mas não aprofundaremos neste trabalho para aprofundar esta diferença. Essa característica foi considerada no processo de avaliação da qualidade das recomendações geradas pelo modelo.

3.7. Habilidades Mais Frequentes no Catálogo

O levantamento das 15 habilidades (skills) mais presentes nos cursos foi realizado por meio da explosão da coluna skills, que contém múltiplas habilidades separadas por vírgula em cada registro. Habilidades como Machine Learning (468), Python Programming (412), Data Analysis (387), Deep Learning (334) e Statistical Programming (298) figuram entre as mais frequentes, refletindo a vocação da plataforma para conteúdos de tecnologia e análise de dados.

Essa análise é diretamente relevante para o sistema de recomendação, pois a coluna skills recebeu peso duplo na engenharia de features. Isso garante que habilidades com alta frequência no catálogo exerçam maior influência na similaridade calculada entre os cursos. O total de habilidades únicas presentes na base foi

calculado e exibido ao final da célula, fornecendo uma visão da riqueza do vocabulário técnico disponível para vetorização.




Figura 2 – Nota média por dificuldade e top 15 habilidades mais frequentes

3.8. Padrões e Características Relevantes Identificados

A análise exploratória em conjunto revelou padrões estruturais relevantes para a modelagem do sistema de recomendação, que podem ser sintetizados em quatro dimensões principais:

Concentração de oferta: poucas instituições (predominantemente empresas de tecnologia e grandes universidades norte-americanas) respondem pela maior parte do catálogo disponível. Isso implica que as recomendações geradas pelo modelo tendem, naturalmente, a privilegiar cursos dessas instituições, o que deverá ser considerado na análise de diversidade.

Viés de avaliação positiva: a distribuição das notas é assimétrica à esquerda, com a maioria dos cursos avaliados entre 4,0 e 4,9. Essa característica reduz a necessidade de filtro por qualidade mínima, mas também limita o poder discriminatório da variável rating como critério isolado de recomendação, reforçando a escolha pela abordagem baseada em conteúdo (TF-IDF sobre atributos textuais).

Vocação temática em tecnologia: as habilidades mais frequentes (Machine Learning, Python Programming, Data Analysis, Deep Learning) confirmam a forte especialização da plataforma em conteúdo de ciência de dados e tecnologia, o que é coerente com o perfil esperado dos usuários do sistema de recomendação desenvolvido neste trabalho.

Riqueza textual para vetorização: as colunas description e skills, combinadas, fornecem um vocabulário técnico diversificado que sustenta a eficácia da vetorização TF-IDF. Quanto maior e mais específico o texto de cada curso, mais precisa tende a ser a representação vetorial e, conseqüentemente, o cálculo de similaridade entre cursos — elemento central da abordagem de filtragem baseada em conteúdo adotada neste projeto.